

Universidad Politécnica de Madrid (UPM)
ETS de Ingenieros Informáticos
Grado en Ciencia de Datos e IA



UNIVERSIDAD
POLITÉCNICA
DE MADRID

KDD en el Dominio del Clima

Por Laura García Perrín y Xiya Sun

Índice de Contenidos


- Dominio y Procesamiento de Datos
 - Objetivos del Proyecto
 - Técnicas de *Data Mining*
 - Evaluación y Resultados
 - Aspectos Mejorables
 - Conclusiones Finales
-



Dominio y Procesamiento de Datos

- Dominio: clima
- Fuente de Datos: Kaggle [1]
- 96453 instancias o filas
- 12 variables o columnas

Pipeline del Procesamiento de Datos



Característica	Tipo de Datos	Descripción
Formatted Date	datetime64[ns, UTC]	Fecha y hora en formato UTC
Summary	object	Resumen del clima para el día
Precip Type	object	Tipo de precipitación
Temperature (C)	float64	Temperatura en C°
Apparent Temperature (C)	float64	Temperatura aparente en C°
Humidity	float64	Humedad relativa en porcentaje
Wind Speed (km/h)	float64	Velocidad del viento en km/h
Wind Bearing (degrees)	float64	Dirección del viento en grados
Visibility (km)	float64	Visibilidad en km
Loud Cover	float64	Cobertura de nubes
Pressure (millibars)	float64	Presión atmosférica en milibares
Daily Summary	object	Resumen del clima para el día

[1] <https://www.kaggle.com/datasets/muthuj7/weather-dataset/data>






Objetivos del Proyecto

Objetivo principal → análisis temporal de tendencias climáticas.

Otros propósitos:

- ★ Lanzar predicciones
- ★ Identificar fenómenos climáticos
- ★ Identificar patrones y grupos



Técnicas de Data Mining



KMeans

✓ Análisis



10 grupos
climáticos

(S)ARIMA

✓ Predicciones



Resultados
mejorables de
precisión y de
latencia

Random Forest
Regressor

✓ Predicciones



Buenos
resultados de
precisión

CNNs

✓ Análisis



Detecta
eficazmente
características
de ST

Evaluación y Resultados



KMeans

- Silhouette Score: 0.2447
- Davies-Bouldin Index: 1.3159
- Calinski-Harabasz Index: 22616.9146

(S)ARIMA

- MAE: 197.4030
- MSE: 50431.0512
- RMSE: 224.5685
- MAPE: 62.6810

Random Forest Regressor

- MAE: 0.0122
- MSE: 0.0019
- RMSE: 0.0443
- MAPE: 0.0076
- R-squared: 0.9999

CNNs

- Test loss: 0.4592
- Test accuracy: 0.9743




Consideraciones - Clustering KMeans

Satisface los objetivos de:

- Identificar patrones y tendencias.
- Identificar clústeres asociados con eventos climáticos extremos.
- Agrupar datos en patrones distintivos; identificar tendencias y cambios a lo largo del tiempo.

Guarda una serie de **contrapartidas**:

- Sensible a los outliers
- Capacidad limitada para captar patrones complejos






Consideraciones - (S)ARIMA

Satisface los objetivos de:

- Modelizar la evolución de una variable en el tiempo
- Identificar características o eventos climáticos.
- Predecir valores futuros basado en valores pasados (autoregresión).

Guarda una serie de **contrapartidas**:

- Malos resultados
- Muy lento; poco optimizado
- Requiere de un análisis previo algo exhaustivo



Consideraciones - Random Forest Regressor





Satisface los objetivos de:

- Lanzar predicciones.
- Identificar patrones y tendencias en los datos climáticos.

✓ Parece arrojar buenos resultados de predicción

➡ Latencia mejorable



Consideraciones - CNN





Satisface los objetivos de:

- Extraer características de las series temporales y clasificarlas
- Identificar patrones visuales que reflejan cambios climáticos significativos.

✓ Diferencia bien entre series temporales

✓ Latencia deseable


✓ Método novedoso y de actualidad



Aspectos Mejorables



Aspecto Mejorable	Propuesta
Latencia en Métodos Estadísticos	Paralelizar las funciones o recurrir a otras herramientas y/o lenguajes de programación, como R o Weka.
Flexibilidad	Elaborar de métodos y funciones que sean trasladables a la hora de entrenar y evaluar modelos.
Innovar y Explorar	Investigar nuevas metodologías que sean de interés en la actualidad dada su relevancia, eficiencia y rendimiento.



23 funciones implementadas



Método	Tiempo de Ejecución (segundos)
<code>impute_precip_type_na_as_snow</code>	5.15
<code>preprocess_weather_data</code>	6.13
<code>apply_kmeans</code>	9.56
<code>fit_sarima</code>	131.50
<code>train_sarima</code>	97.52
<code>forecast_sarima</code>	1.57
<code>prepare_rf</code>	42.45
<code>crear_series_temporales</code>	0.13
<code>recurrence_plot</code>	0.22
<code>prepare_training_data</code>	22.50
<code>train_and_evaluar_model</code>	11.48



Conclusiones finales

- ★ El proceso KD (*Knowledge Discovery*) incluye varias etapas clave
- ★ No hay una única metodología para el KD
 - Depende del dominio y de los objetivos
 - Siempre hay espacio para mejoras
- ★ La finalidad subyacente es descubrir conocimientos útiles no evidentes
- ★ Las técnicas de Data Mining se alinean con los objetivos y tienen diferentes contribuciones
 - Ofrecen una visión integral del problema y/o conjunto de datos
 - Son perspectivas diferentes

Universidad Politécnica de Madrid (UPM)
ETS de Ingenieros Informáticos
Grado en Ciencia de Datos e IA



UNIVERSIDAD
POLITÉCNICA
DE MADRID

Gracias por su Atención

Laura García Perrín y Xiya Sun